

# Постановка задачи

---

Есть список слов-омонимов.

Для каждого слова есть 2 и более определения.

Для каждого слова есть набор размеченных текстов, где это слово встречается в одном из смыслов, упомянутых выше.

Требуется автоматически выбрать одно определение омонима из списка определений так, чтобы оно совпало с тем, что указано в разметке.

Пример размеченного омонима:

```
"байка": {
  "meanings": [
    {
      "index": 0,
      "определение": "юмористический рассказ, как правило, основанный на реальных",
    },
    {
      "index": 1,
      "определение": "мягкая ворсистая хлопчатобумажная или шерстяная, полушерстя",
    }
  ],
  "samples": [
    {
      "text": "А пока Вы читали мои байки, я вспомнила ещё одну историю",
      "meaning": 0
    },
    {
      "text": "Фланель и байка имеют на поверхности маленькие ворсинки, из них то",
      "meaning": 1
    },
    {
      "text": "она всё лето прела под чёрной байкой для того, чтобы иметь удовольь",
      "meaning": 1
    }
  ]
},
```

Корневой элемент - омоним, который содержит два списка: список определений и список примеров на каждое определение.

Для решения задачи использовалось 2 подхода:

1. Подход со сравнением примера и значения
2. Подход с обучением отдельного классификатора для каждого омонима

## Подход со сравнением примера и значения

---

### Описание

Определения и примеры переводились в вектора, потом каждый пример сравнивался с каждым определением. По наибольшему показателю метрики принималось решение, что пример соответствует конкретному определению.

Для преобразования текстов в вектора использовались различные эмбединги: w2v, d2v, navес, gensim\_pretrainde, bert различных моделей: cointegrated/rubert-tiny, cointegrated/rubert-tiny2, sberbank-ai/sbert\_large\_nlu\_ru, sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2, DeepPavlov/rubert-base-cased-sentence, DeepPavlov/rubert-base-cased, inkoziev/sbert\_synonymy

Тексты преобразовывались в вектора с варьированием лемматизации и удаления слов. Итоговый вектор текста получался тремя способами: либо вычислялось среднеарифметическое значение вектора поэлементно и получался вектор из среднеарифметических значений, либо значения векторов складывались поэлементно, либо использовался как есть, если его давали на весь текст, а не на каждое слово отдельно.

Метрики: косинусное сходство, метрики из sklearn: euclidean, manhattan, minkowski, hamming, canberra, braycurtis.

Корпуса:

- homonyms\_ru\_clean.json - корпус вначале собранный с сайта [homonyms.ru](https://homonyms.ru) и потом вручную очищен.
- homonyms\_ru\_dirty.json - корпус собранный с сайта [homonyms.ru](https://homonyms.ru) без ручной обработки.
- homonyms\_with\_50\_samples.json - корпус собранный с различных сайтов вручную. Каждый омоним имеет минимум по 20 примеров и не менее 50 примеров в общем.

Метод w2v

| Корпус                        | Метрика   | Всего слов | Соотношение | Доля угаданных | Параметры                                                                                         |
|-------------------------------|-----------|------------|-------------|----------------|---------------------------------------------------------------------------------------------------|
| homonyms_with_50_samples.json | manhattan | 10         | 279/586     | 0.4761         | лемматизация = False<br>Удаление стоп-слов True, Вектор - сумма значений поэлемент                |
| homonyms_ru_clean.json        | manhattan | 26         | 103/187     | 0.5508         | лемматизация = True<br>Удаление стоп-слов False, Вектор - среднеарифметическое значение поэлемент |
| homonyms_ru_dirty.json        | canberra  | 57         | 154/414     | 0.3720         | лемматизация = True<br>Удаление стоп-слов True, Вектор - сумма значений поэлемент                 |

Метод navес

| Корпус                        | Метрика           | Всего слов | Соотношение | Доля угаданных | Параметры                                          |
|-------------------------------|-------------------|------------|-------------|----------------|----------------------------------------------------|
| homonyms_with_50_samples.json | similarity_cosine | 10         | 348/586     | 0.5939         | лемматизация = True,<br>Удаление стоп-слов = True  |
| homonyms_ru_clean.json        | similarity_cosine | 26         | 98/187      | 0.5241         | лемматизация = True,<br>Удаление стоп-слов = False |
| homonyms_ru_dirty.json        | similarity_cosine | 57         | 188/419     | 0.4487         | лемматизация = True,<br>Удаление стоп-слов = True  |

#### Метод gensim\_pretrainde, модель = word2vec-ruscorpora-300

| Корпус                        | Метрика    | Всего слов | Соотношение | Доля угаданных | Параметры                                                                                             |
|-------------------------------|------------|------------|-------------|----------------|-------------------------------------------------------------------------------------------------------|
| homonyms_with_50_samples.json | braycurtis | 10         | 380/586     | 0.6485         | лемматизация = True<br>Удаление стоп-слов : False, Вектор - среднеарифметическое значение поэлементно |
| homonyms_ru_clean.json        | canberra   | 26         | 113/187     | 0.6043         | лемматизация = True<br>Удаление стоп-слов : False, Вектор - среднеарифметическое значение поэлементно |
| homonyms_ru_dirty.json        | canberra   | 57         | 216/419     | 0.5155         | лемматизация = True<br>Удаление стоп-слов : False, Вектор - среднеарифметическое значение поэлементно |

#### Метод d2v

| Корпус | Метрика | Всего слов | Соотношение | Доля угаданных | Параметры |
|--------|---------|------------|-------------|----------------|-----------|
|--------|---------|------------|-------------|----------------|-----------|

| Корпус                        | Метрика           | Всего слов | Соотношение | Доля угаданных | Параметры                                          |
|-------------------------------|-------------------|------------|-------------|----------------|----------------------------------------------------|
| homonyms_with_50_samples.json | similarity_cosine | 10         | 266/586     | 0.4539         | лемматизация = False,<br>Удаление стоп-слов = True |
| homonyms_ru_dirty.json        | euclidean         | 57         | 154/420     | 0.3667         | лемматизация = True,<br>Удаление стоп-слов = True  |
| homonyms_ru_clean.json        | canberra          | 26         | 94/187      | 0.5027         | лемматизация = True,<br>Удаление стоп-слов = False |

#### Метод bert\_score, модель: cointegrated/rubert-tiny

| Корпус                        | Метрика  | Всего слов | Соотношение | Доля угаданных |
|-------------------------------|----------|------------|-------------|----------------|
| homonyms_with_50_samples.json | canberra | 10         | 343/586     | 0.5853         |
| homonyms_ru_clean.json        | canberra | 26         | 107/187     | 0.5722         |
| homonyms_ru_dirty.json        | canberra | 57         | 193/420     | 0.4595         |

#### Метод bert\_score, модель: cointegrated/rubert-tiny2

| Корпус                        | Метрика    | Всего слов | Соотношение | Доля угаданных |
|-------------------------------|------------|------------|-------------|----------------|
| homonyms_with_50_samples.json | braycurtis | 10         | 414/586     | 0.7065         |
| homonyms_ru_clean.json        | manhattan  | 26         | 129/187     | 0.6898         |
| homonyms_ru_dirty.json        | manhattan  | 57         | 230/420     | 0.5476         |

#### Метод bert\_score, модель: sberbank-ai/sbert\_large\_nlu\_ru

| Корпус                        | Метрика   | Всего слов | Соотношение | Доля угаданных |
|-------------------------------|-----------|------------|-------------|----------------|
| homonyms_with_50_samples.json | minkowski | 10         | 387/586     | 0.6604         |
| homonyms_ru_clean.json        | manhattan | 26         | 117/187     | 0.6257         |
| homonyms_ru_dirty.json        | manhattan | 57         | 208/420     | 0.4952         |

## Метод bert\_score, модель: sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2

| Корпус                        | Метрика    | Всего слов | Соотношение | Доля угаданных |
|-------------------------------|------------|------------|-------------|----------------|
| homonyms_with_50_samples.json | braycurtis | 10         | 416/586     | 0.7099         |
| homonyms_ru_clean.json        | braycurtis | 26         | 131/187     | 0.7005         |
| homonyms_ru_dirty.json        | braycurtis | 57         | 241/420     | 0.5738         |

## Метод bert\_score, модель: DeepPavlov/rubert-base-cased-sentence

| Корпус                        | Метрика    | Всего слов | Соотношение | Доля угаданных |
|-------------------------------|------------|------------|-------------|----------------|
| homonyms_with_50_samples.json | manhattan  | 10         | 392/586     | 0.6689         |
| homonyms_ru_dirty.json        | minkowski  | 57         | 227/420     | 0.5405         |
| homonyms_ru_clean.json        | braycurtis | 26         | 119/187     | 0.6364         |

## Метод bert\_score, модель: DeepPavlov/rubert-base-cased

| Корпус                        | Метрика    | Всего слов | Соотношение | Доля угаданных |
|-------------------------------|------------|------------|-------------|----------------|
| homonyms_with_50_samples.json | canberra   | 10         | 301/586     | 0.5137         |
| homonyms_ru_dirty.json        | canberra   | 57         | 162/420     | 0.3857         |
| homonyms_ru_clean.json        | braycurtis | 26         | 107/187     | 0.5722         |

## Метод bert\_score, модель: inkoziev/sbert\_synonymy

| Корпус                        | Метрика   | Всего слов | Соотношение | Доля угаданных |
|-------------------------------|-----------|------------|-------------|----------------|
| homonyms_with_50_samples.json | canberra  | 10         | 333/586     | 0.5683         |
| homonyms_ru_dirty.json        | manhattan | 57         | 175/420     | 0.4167         |
| homonyms_ru_clean.json        | canberra  | 26         | 113/187     | 0.6043         |

## Выводы

После очистки корпуса homonyms\_ru он стал вдвое меньше и результаты по нему выросли на 10% и более процентов, в зависимости от метода.

Лучше всего с задачей снятия омонимов справляется эмбединг на основе bert с моделями rubert-tiny2 и paraphrase-multilingual-MiniLM-L12-v2. Лучший результат находится на уровне 0.70 доли правильно снятых омонимов. В них разница между корпусами homonyms\_with\_50\_samples и homonyms\_ru\_clean минимальна, не более двух процентов.

Ввиду того, что первый корпус собирался полностью вручную и имеет в 2 раза меньше различных омонимов для снятия, считаю, что метод справляется достаточно хорошо, так как разница в результате небольшая.

## Подход с обучением отдельного классификатора для каждого омонима

### Описание

Примеры переводились в вектора, каждому из которых ставилась в соответствие метка - номер определения.  
Далее 60% примеров бралось на обучение и 40% на тест.  
Для классификации использовались классификаторы svm, RandomForest, K Neighbors с различными параметрами.

Для преобразования текстов в вектора использовались различные эмбеддинги: w2v, tfidf, bert различных моделей: sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2, cointegrated/rubert-tiny2, cointegrated/rubert-tiny.

Корпуса:

- homonyms\_ru\_clean.json - корпус вначале собранный с сайта [homonyms.ru](https://homonyms.ru) и потом вручную очищен.
- homonyms\_with\_50\_samples.json - корпус собранный с различных сайтов вручную. Каждый омоним имеет минимум по 20 примеров и не менее 50 примеров в общем.

С корпусом homonyms\_ru\_dirty.json классификаторы не завелись из-за нехватки данных для разметки.

### Метод w2v

| Корпус                        | Классификатор | F1_macro_avg | F1_micro_avg | Параметры                                      |
|-------------------------------|---------------|--------------|--------------|------------------------------------------------|
| homonyms_ru_clean.json        | RandomForest  | 0.3704       | 0.4392       | n_estimators=150<br>entropy<br>bootstrap=False |
| homonyms_with_50_samples.json | RandomForest  | 0.5608       | 0.5762       | n_estimators=150<br>entropy<br>bootstrap=False |

### Метод Tfidf

| Корпус                        | Классификатор | F1_macro_avg | F1_micro_avg | Параметры                       |
|-------------------------------|---------------|--------------|--------------|---------------------------------|
| homonyms_with_50_samples.json | SVM           | 0.6999       | 0.7039       | class_weight=balanced<br>linear |

| Корпус                 | Классификатор | F1_macro_avg | F1_micro_avg | Параметры                    |
|------------------------|---------------|--------------|--------------|------------------------------|
| homonyms_ru_clean.json | RandomForest  | 0.4332       | 0.3237       | entropy<br>max_features=log2 |

#### Метод bert\_score, модель: rubert-tiny

| Корпус                        | Классификатор | F1_macro_avg | F1_micro_avg | Параметры                                          |
|-------------------------------|---------------|--------------|--------------|----------------------------------------------------|
| homonyms_with_50_samples.json | SVM           | 0.7686       | 0.7743       | class_weight=balanced<br>kernel=poly<br>coef0=0.75 |
| homonyms_ru_clean.json        | SVM           | 0.4330       | 0.5165       | class_weight=balanced<br>linear                    |

#### Метод bert\_score, модель: paraphrase-multilingual-MiniLM-L12-v2

| Корпус                        | Классификатор | F1_macro_avg | F1_micro_avg | Параметры                                      |
|-------------------------------|---------------|--------------|--------------|------------------------------------------------|
| homonyms_with_50_samples.json | SVM           | 0.8464       | 0.8509       | kernel=poly<br>degree=4<br>coef0=0.75          |
| homonyms_ru_clean.json        | RandomForest  | 0.3171       | 0.4219       | n_estimators=150<br>entropy<br>bootstrap=False |

#### Метод bert\_score, модель: rubert-tiny2

| Корпус                        | Классификатор | F1_macro_avg | F1_micro_avg | Параметры                                          |
|-------------------------------|---------------|--------------|--------------|----------------------------------------------------|
| homonyms_with_50_samples.json | SVM           | 0.8359       | 0.8401       | class_weight=balanced<br>kernel=poly<br>coef0=0.75 |
| homonyms_ru_clean.json        | SVM           | 0.4158       | 0.5088       | class_weight=balanced<br>linear                    |

### Выводы

Здесь также, как и в предыдущем разделе лучше всего справились bert-модели paraphrase-multilingual-MiniLM-L12-v2 и rubert-tiny2 с результатом 0.8359 - 0.8509 средних микро- и макро-f-меры на корпусе homonyms\_with\_50\_samples. У второго корпуса результаты отстают на 30-40%. Это можно объяснить тем, что корпус homonyms\_with\_50\_samples имеет больше примеров на каждый омоним, что позитивно влияет на обучение. Кроме того, корпус homonyms\_ru\_clean имеет больше разлных омонимов с меньшим количеством примеров, что сильно сказывается на показателях метрик.